

融合古籍信息的中医药知识图谱推理研究^{*}

韩 青¹ 周晓英²

¹(浙江中医药大学医学技术与信息工程学院 杭州 310053)

²(中国人民大学信息资源管理学院 北京 100872)

摘要:【目的】针对中医药知识图谱存在结构稀疏、语义信息利用不足等问题,将中医古籍文本作为实体描述信息引入表示学习模型,以提升知识图谱推理性能。【方法】以《伤寒论》398 条条文为语料,通过人工标注与自动抽取相结合的方式构建经方知识图谱,并将《伤寒论》及《金匱要略》中与实体相关的条文作为实体描述语料输入预训练语言模型。在 TransE、DistMult、ComplEx、Simple 等基线模型上分别融合静态 BERT 表示(BERT-Static)和端到端微调 BERT 表示(BERT-Dynamic)进行知识图谱推理实验。【结果】在经方知识图谱上,融合古籍信息后的推理模型在 MRR、Hits@1、Hits@3、Hits@10 等指标上的性能均明显优于对应的基线模型。从绝对数值看,MRR 由 0.062~0.089 提升至 0.257~0.270, Hits@10 由 0.148~0.181 提升至 0.513~0.547。文本长度消融实验表明:当 BERT 输入长度由 16 增加至 96 个中文字符时,模型性能持续提升;但超过 96 个中文字符后性能提升不再显著,而训练时间近似线性增长。【局限】本研究实验数据主要来源于《伤寒论》及《金匱要略》相关条文,知识图谱规模相对有限;方法上仅考虑实体描述信息与结构三元组的联合表示,未纳入关系路径与规则推理等结构增强信息。【结论】将中医古籍文本作为实体描述信息并与预训练语言模型结合,能够有效增强中医药知识表示能力,显著提升中医药知识图谱推理性能。

关键词: 中医药 中医古籍 知识图谱推理 预训练语言模型 经方知识图谱 表示学习

分类号: G255 TP391.1 R2-03

DOI: 10.11925/infotech.2096-3467.2024.0259

引用本文: 韩青, 周晓英. 融合古籍信息的中医药知识图谱推理研究[J]. 数据分析与知识发现, 2026, 10(3): 25-36. (Han Qing, Zhou Xiaoying. Knowledge Graph Reasoning for Traditional Chinese Medicine Enhanced by Classical Texts[J]. Data Analysis and Knowledge Discovery, 2026, 10(3): 25-36.)

1 引 言

中医药是中国传统医学思想与中华智慧的集中体现,是中华民族几千年医疗实践的历史证据和现实载体。近年来,为提高中医药资源挖掘与利用的效率,众多学者围绕中医药知识图谱构建与应用开展了一系列从理论到技术的多层次研究。如,名老中医医案知识图谱构建^[1-2]、中医药命名实体识别^[3]与关系抽取^[4-5]、中医智能问答^[6-7]与用药推荐^[8-9]等。然而,目前中医药知识图谱的构建仍然面临人工标

注成本高、自动抽取准确率低、实体关系不完整、知识更新滞后等问题,使得中医药知识图谱的表示能力与推理能力受到较大限制,难以有效支撑复杂的临床推理与智能决策任务,制约了中医药知识图谱智能化应用的范围和效果。因此,如何在已有中医药知识图谱基础上,通过表示学习与知识增强技术实现推理性能的提升,补全并完善现有中医药知识图谱,提高处方推荐、药物再利用与辅助决策的效能,是当前研究急需探索的重要问题。

通讯作者(Corresponding author): 周晓英(Zhou Xiaoying), ORCID: 0000-0002-9116-1525, E-mail: xyz-ruc@qq.com。

^{*}本文系国家自然科学基金重大项目(项目编号: 21&ZD335)的研究成果之一。

The work is supported by the Major Project of the National Social Science Fund of China (No. 21&ZD335).

知识图谱推理是一种将推理任务限定在图结构基础之上的关系推理和事实预测,旨在基于图谱中已有的实体与关系信息,推断出潜在或未知的三元组信息,从而实现图谱的自动补全与智能推理。很多现实的问题,如智能推荐、因果分析、查询问答和实体对齐等都可以归结为实体之间的关系推理问题。随着表示学习(Representation Learning, RL)技术迅速发展,基于表示学习的知识图谱推理受到研究者的广泛关注^[10]。基于表示学习的知识推理的基本思想是将知识图谱中的实体和关系投影到向量空间中,将推理转化为基于表示模型的简单向量操作,使知识图谱的推理能够通过向量空间之间的计算自动实现^[11]。典型的如 TransE^[12]、DistMult^[13]、ComplEx^[14]等基于翻译假设的表示学习模型,通过低维向量建模三元组关系,从而实现高效的推理。这类方法虽然具有良好的计算效率与泛化能力,但往往仅依赖知识图谱中的结构特征信息,忽略了知识图谱实体包含的丰富语义描述信息。为进一步提升基于表示学习的知识图谱推理性能,研究者引入实体的文本描述信息,在学习知识图谱三元组结构特征的基础上,提出融合实体描述信息的知识表示学习模型 DKRL (Description-Embodied Knowledge Representation Learning)^[15]。然而,不同知识领域实体描述信息的语义特征差异较大^[16],同一领域内实体描述信息的来源也有多种选择,选择高质量、具备语义深度的实体描述信息资源,是提升知识图谱推理效果的关键环节。

中医古籍中蕴含大量有价值的潜在知识,既有中医药知识图谱实体描述信息,也包含与此相关的上下文语义信息,是一类承载高密度领域知识的语义资源。如《黄帝内经》《伤寒论》《金匱要略》等经典古籍中,不仅系统记载了中医理论、辨证施治逻辑与方药知识,还包含大量与中医药知识图谱实体高度相关的文本语义信息,如方剂组成、疾病证候、药性药味、经络归属、配伍禁忌等^[17]。如果这些信息能被有效结构化,并与知识图谱实体进行关联,将极大地增强中医药知识图谱的表达能力与语义关联能力,成为实现语义增强推理的关键路径。

基于此,本研究提出一种融合中医古籍语义信息的中医药知识推理方法。以汉代名医张仲景所著

的《伤寒论》作为中医药领域的代表性实例进行研究。首先构建中医经方知识图谱,在结构化的中医药经方知识图谱基础上,引入古籍中相关的条文语句作为实体描述信息,并结合预训练语言模型实现实体的语义增强表示;然后,设计联合训练框架,融合结构向量与语义向量,实现中医药知识的智能推理与知识图谱补全,为中医药知识智能建模与推理应用提供一种可扩展、可迁移的新路径,并验证中医古籍信息在中医药知识图谱推理中的价值与潜力。

2 相关研究

知识图谱推理旨在利用已有的实体与关系三元组推断潜在知识,是实现智能问答、辅助推荐与因果发现等任务的核心技术。在现有方法中,基于规则的推理和基于图结构的推理均显式定义了推理所需的特征,而基于表示学习的知识图谱推理则通过将知识图谱中的实体和关系进行向量化表示来实现对实体和关系语义信息的准确描述^[18]。因建模效率高、可扩展性强,表示学习方法在大规模知识图谱推理任务中显示出较强优势,成为当前主流研究方向之一。

2.1 基于结构特征的表示学习方法

TransE 模型^[12]是一种基于翻译假设的表示学习模型,该模型将知识图谱三元组中的关系建模为实体之间的向量平移操作,在 WN18、FB15K 等基准数据集上表现出良好的性能。虽然 TransE 模型简单高效、计算复杂度低,在大规模稀疏知识库上具有较好的性能与可扩展性,但由于其关系建模过于简化,无法有效处理一对多、多对一等复杂关系。后续模型则通过增加实体和关系建模复杂度进一步提升 TransE 的表示能力。如,TransH 模型^[19]让一个实体在不同的关系下拥有不同的表示,通过设计关系投影平面提升 TransE 表达非一对一关系的能力。TransR 模型^[20]则通过拆分实体向量表示空间和关系向量表示空间提升 TransE 的表达能力。为减少 TransR 的参数量同时保留其表达能力,TransD^[21]用一个与实体相关的向量以及一个与关系相关的向量,通过外积计算动态地得到关系投影矩阵。TransE 及其扩展模型的核心思想与技术特征如表 1 所示。

表 1 TransE 及其扩展模型的核心思想与技术特征比较

Table 1 Comparison of Core Ideas and Technical Characteristics of Trans-series Knowledge Graph Embedding Models

模型名称	提出年份	核心思想	技术改进点	优势	局限性
TransE	2013	将关系建模为实体间的平移操作	原始模型	简单高效,计算成本低	无法处理一对多、多对一、多对多等复杂关系
TransH	2014	引入超平面以支持实体在不同关系中有不同表示	关系特异性表示空间	适应非 1 对 1 关系,效果提升	参数量增多,训练成本上升
TransR	2015	将实体与关系嵌入不同空间	显式关系空间建模	表达能力强,适应性好	模型复杂度高,参数多
TransD	2015	动态生成投影矩阵	减少参数,保持表达力	性能优,内存友好	描述能力仍受限于线性结构

针对上述翻译类模型在表达性能上的不足,研究者提出基于张量分解或复数空间的模型。如,DistMult^[13]采用更灵活的线性映射假设,将实体表示为向量,关系表示为矩阵,并将关系当作一种向量空间中的线性变换,以双线性函数建模三元组关系;Complex^[14]将实体与关系嵌入复数空间,有效建模非对称关系,克服了DistMult不能很好地表示非对称关系的问题;RotatE^[22]、QuatE^[23]等则进一步扩展向量运算形式,提高模型的表达力与收敛速度。

上述方法在FB15K-237、WN18RR等通用领域知识图谱基准数据集上均表现出良好的知识图谱推理性能,但它们仅依赖图结构信息,难以应对图谱稀疏、实体新颖性高的场景,尤其是在特定领域如中医药中,图谱结构往往不完备、语义隐含性强,表现效果受限。

2.2 融合实体语义描述的表示学习方法

为提升推理模型在低资源场景下的泛化能力,研究者逐步将实体的语义描述信息引入表示学习。实体描述是对实体自身信息浓缩性文字介绍,通常由几句话或一个段落组成。实体描述信息蕴含丰富的实体语义信息,这些信息能够作为结构化信息的辅助信息,用于改善数据稀疏问题。如,Xie等^[15]提出融合实体描述信息的知识表示学习模型DKRL,将实体描述作为输入,通过卷积神经网络提取描述向量,与结构表示共同参与三元组评分函数学习,在知识图谱补全和实体类型分类等任务上均取得了超过基线模型的效果。

随着预训练语言模型(Pre-Trained Language Models, PLMs)的迅速发展,其强大的语义建模能力被广泛用于知识图谱推理任务中,PLMs在提升表示学习与知识推理能力方面取得了显著进步^[24]。如,

KG-BERT模型^[25]首次将PLMs用于三元组分类任务,将三元组转化为文本输入,模型无需结构嵌入,其性能显著优于传统基于翻译假设的推理模型;Wang等^[26]利用PLMs对实体描述进行编码,将实体描述编码与知识嵌入联合优化,并引入对比学习机制,提出联合训练框架KEPLER,在关系分类、知识推理等任务上较传统模型取得了显著性能提升;CoLAKE^[27]、K-BERT^[28]、ERNIE^[29]等模型则通过图谱注入、知识引导或联合训练策略,进一步提升了文本与结构融合方法的表示学习能力。

实体描述的来源十分丰富,可以在知识图谱构建过程中由人工填写,也可以从百科类数据库中提取,还能从丰富的网页文本中抽取。同时,实体描述往往在长度、有效信息、噪声形式、描述质量等方面存在较多差异,这就要求模型考虑差异化的文本输入,减少文本中无用信息的干扰。因此,如何抽取高质量的实体相关知识是此类知识图谱推理方法的关键。然而,现有知识图谱推理方法主要依赖Wikipedia、ConceptNet等通用语料库或开放百科类资源,这些资源中的实体描述往往质量较高、结构规范、语义清晰。但对于中医药等专业领域,现成的语义描述资源稀缺,实体描述信息通常需从专业古籍文献或专业文档中提取,这一过程面临诸多挑战。如,实体文本存在高度异质性,语义密度和语言风格差异显著,难以统一建模;文本噪声问题普遍存在,中医古籍常用词晦涩、缺乏明确边界,且多为非结构化文本,增加了信息抽取的复杂性;结构表示与语义表示之间存在融合冲突,缺乏通用且高效的统一建模机制;预训练语言模型的泛化能力在低资源专业语境中表现不稳定,难以直接迁移到中医药等细分领域。因此,如何有效构建高质量的实体语义描述,

并将其与结构信息融合,仍是专业知识图谱推理任务亟需突破的关键问题。

作为中医药知识的重要语义载体,中医古籍虽存在文本异质性与文本噪声等问题,同时也具备高置信度、语义聚焦、描述密度高等特点。若能将其条文信息有效转化为实体描述信息并融入预训练语言模型驱动的知识表示框架,有望显著提升中医药知识图谱的推理能力。因此,本研究提出一种融合中医古籍信息的中医药知识图谱推理方法,即将古籍中的经方条文信息作为实体语义描述,通过预训练语言模型实现语义增强表示,联合结构嵌入共同参与知识推理建模。

3 融合古籍信息的中医药知识推理

3.1 总体框架

知识图谱推理是一类在已有三元组结构基础上进行关系预测与事实补全的关键技术,其目标是利用知识图谱中已知的实体关系,推断未知的实体关联关系。在中医药领域,基于知识图谱的推理任务旨在利用现有中医药实体间的结构信息,挖掘出新的方证对应关系、药物组合路径或诊疗建议,提升知

识图谱的完备性与智能服务能力。为增强推理模型对语义特征的捕捉能力,本研究在传统结构三元组基础上引入实体的文本描述信息,特别是来源于古籍的高质量语义文本。

将包含实体相关古籍描述的中医药知识图谱形式化定义为一个元组: $KG = (E, R, T, D)$,其中, E 表示实体集合, R 表示关系类型集合, T 表示三元组集合, D 表示实体相关的古籍文本描述集合。

对于任意三元组 $(e_i, r_j, e_k) \in T$,其中, $e_i, e_k \in E$ 是三元组的头实体和尾实体, $r_j \in R$ 是三元组实体间的关系类型。每一个实体 $e_i \in E$ 对应于一个文本描述 $d_{e_i} = (w_1, w_2, \dots, w_n) \in D$,其中, w_i 为词汇表 V 中的词项。

实体和关系分别被映射为向量空间中的表示:对于单个实体 $e_i \in E$,将其表示为一个实体向量 $e_i \in \mathbb{R}^d$;对于一类关系 $r_j \in R$,将其表示为一个关系向量 $r_j \in \mathbb{R}^d$;其中, d 表示向量的维度。本研究提出的中医药知识图谱推理框架主要包括两个模块:基于预训练语言模型的实体语义表示学习模块和关系嵌入建模与推理函数设计模块。完整框架结构如图1所示。




图1 融合古籍信息的中医药知识图谱推理方法

Fig.1 Knowledge Graph Reasoning Method for Traditional Chinese Medicine with Classical Texts

3.2 基于预训练模型的实体表示学习

表示学习的核心目标是将知识图谱中的实体和关系编码为低维稠密向量,进而实现基于向量操作的知识推理。近年来,Transformer架构的发展推动了BERT等大规模预训练语言模型在文本建模中的广泛应用。通过对大语料库的预训练,这类模型能够自动捕捉词汇的上下文信息,获得具有丰富语义的文本表示^[30]。对于不同的下游任务,只需对预训练语言模型进行微调(Fine-Tuning),就可以实现文

本的表示学习^[31]。

本研究选用BERT模型作为实体描述的表示学习模型,与DKRL模型^[15]等早期方法相比,基于BERT的实体表示学习无需在输入端进行停用词处理等额外预处理步骤,可直接输入原始古籍文本,更有助于保留描述中隐含的语义信息。

对于某一实体的文本描述 $d_{e_i} = (w_1, w_2, \dots, w_n)$,在其开始处和结尾处分别添加特殊标记[CLS]和[SEP],用于构造输入序列,BERT模型的输入转化

为序列 $\hat{d}_{e_i} = ([CLS], w_1, w_2, \dots, w_n, [SEP])$ 。将其输入 BERT 模型后,输出是包括这两个新增标记长度为 $n+2$ 的上下文嵌入(Contextualized Embeddings):

$$BERT(\hat{d}_{e_i}) = (h_{CLS}, h_1, h_2, \dots, h_n, h_{SEP})$$

参考 Sentence-BERT^[24] 和 KEPLER^[26] 等模型对文本表示学习的处理方法,选取上下文向量 $h_{CLS} \in \mathbb{R}^h$ 作为实体描述的全局语义表示,其中, h 表示 BERT 模型的隐藏尺寸(Hidden Size)。为与结构嵌入向量维度对齐,向量 h_{CLS} 再通过一个线性层(Linear Layer)进行线性变换,获得知识图谱实体表示 $e_i = Wh_{CLS}$ 。其中, $W \in \mathbb{R}^{d \times h}$ 为线性变换的权重参数,最终获得实体的语义增强向量表示。

3.3 关系表示学习与得分函数

基于表示学习的知识图谱推理等价于一个知识图谱实体和关系向量表示的优化问题。即,通过优化算法,找到最能够推理出现有知识的实体和关系向量。在知识图谱推理中,三元组 (e_i, r_j, e_k) 的合理性由得分函数(Scoring Function)进行度量。训练的目标是使真实存在的三元组获得高分,不存在的三元组获得低分。

在模型训练过程中,对于正例三元组(Positive Triple) $(e_i, r_j, e_k) \in T$,其得分函数 $s_p = s(e_i, r_j, e_k)$ 被优化为较高取值;对于通过替换生成的负例三元组(Corrupted Negative Triple) $(e'_i, r_j, e'_k) \notin T$,其得分函数 $s_n = s(e'_i, r_j, e'_k)$ 被优化为较低取值。不同的表示学习模型定义的得分函数略有差异,具体如表 2 所示。对每个关系 $r_j \in \mathbb{R}^d$ 进行随机初始化,并采用随机梯度下降法(Stochastic Gradient Descent, SGD)进行优化。训练过程中,通过动态负采样策略生成负例三元组,以增强模型的学习能力。

表 2 典型表示学习模型的三元组得分函数

Table 2 Triple Scoring Functions of Typical Knowledge Graph Embedding Models

模型	得分函数
TransE	$- e_i + r_j - e_k _p$
DistMult	$\langle e_i, r_j, e_k \rangle$
ComplEx	$Re(\langle e_i, r_j, e_k \rangle)$
Simple	$\frac{1}{2} (\langle e_{i1}, r_{j1}, e_{k1} \rangle + \langle e_{i2}, r_{j2}, e_{k2} \rangle)$

3.4 损失函数设计

在模型训练中,采用边际(Margin-Based)损失函数作为模型优化目标,如公式(1)所示。

$$L = \sum_{(e_i, r_j, e_k) \in T} \max(0, 1 - s(e_i, r_j, e_k) + s(e'_i, r_j, e'_k)) \quad (1)$$

将 Margin 值设定为 1,即希望模型在训练过程中确保正例三元组的得分至少高于负例三元组 1 个单位,如果该间隔不足,模型将产生损失并进行参数更新,从而逐步学习更优的向量表示。损失函数 L 是一个关于 s_p 和 s_n 的函数,该损失函数具有良好的通用性,可适配不同得分函数结构,并支持语义嵌入与结构嵌入的联合训练策略。整体训练流程如下。

算法:融合古籍信息的中医药知识图谱推理

① 输入:知识图谱及实体相关古籍文本 (E, R, T, D) ,带有参数 θ 的实体编码器 f_θ ,学习率 η ,得分函数 s ,损失函数 L

② $r_j \leftarrow$ 随机初始化关系向量 $r_j \in \mathbb{R}$;

③ $\theta := \{\theta\} \cup \{r_j | r \in \mathbb{R}\}$;

④ for $(e_i, r_j, e_k) \in T$ do

⑤ $(e'_i, r_j, e'_k) \leftarrow \text{corrupt}(e_i, r_j, e_k)$;

⑥ $s_p \leftarrow s(f_\theta(d_{e_i}), r_j, f_\theta(d_{e_k}))$;

⑦ $s_n \leftarrow s(f_\theta(d_{e'_i}), r_j, f_\theta(d_{e'_k}))$;

⑧ $\theta \leftarrow \theta - \eta \nabla_\theta L(s_p, s_n)$

⑨ end

⑩ return θ

4 实验与结果分析

4.1 实验数据

为验证融合古籍信息的知识图谱推理方法在中医药领域的适用性与有效性,选取《伤寒论》作为代表性研究对象。以现存版本中最为系统的宋本《伤寒论》为底本,选取其中 398 条条文作为实验语料,构建经方知识图谱,开展知识图谱推理实验。

实验主要包括两个阶段:一是结构抽取层面的经方知识图谱构建;二是语义增强层面的融合中医古籍信息的知识图谱推理。在知识图谱构建阶段,采用人工与自动抽取相结合的方式构建中医经方知识图谱。所构建的图谱作为后续推理任务的结构化输入,同时其实体与《伤寒论》《金匮要

略》等中医古籍中的相关条文进行语义对应,并将这些条文作为实体描述信息用于知识表示学习。

4.2 经方知识图谱构建

(1) 本体设计

经方本体主要根据医学领域本体七步法进行构建,具体包括:定义领域和范畴、调查并复用现有中医药领域本体、提取知识本体中的重要术语与核心概念、定义类和类的等级体系、定义类的属性及其限制、指定属性的分面、创建样本实例^[32]。

对经方知识图谱的本体设计,实际上是对经方概念及其概念间关系的设计,这一过程按上述医学领域本体七步法中的1~6步进行。在领域专家的参与下,根据中医辨证论治逻辑构建出9类概念与5类

关系,如表3和表4所示。

表3 经方知识图谱中的概念类别与示例

Table 3 Concept Categories and Examples in the Jingfang Knowledge Graph

概念类别	示例实体
病因	六淫、寒邪、疫毒
病名	太阳病、阳明病、少阴病
证候	太阳中风、少阴、厥阴
病机	里证、表证、里虚、表未解
症状	发热、咳嗽、呕吐
体征	脉浮、舌红苔黄
方剂	桂枝汤、小柴胡汤、麻黄汤
药物	桂枝、白芍、生姜、大枣
治法	汗法、下法、吐法

表4 经方知识图谱中的关系类型与示例

Table 4 Relation Types and Examples in the Jingfang Knowledge Graph

关系类型	典型关系模式	示例三元组	语义解释
临床表现	病机—临床表现—症状	肺气上逆—临床表现—咳嗽	症状体现病理机制
	病机—临床表现—体征	营卫不和—临床表现—脉浮	体征体现病理机制
治疗	治法—治疗—证候	和法—治疗—少阳证	治法针对特定证候
	方剂—治疗—证候	桂枝汤—治疗—表虚证	某方剂针对特定证候进行治疗
	治法—治疗—证候	汗法—治疗—表证	某治法适用于某类证候
包含	病名—包含—证候	少阴病—包含—里寒外热	某类病名对应的典型证候
	证候—包含—病机	太阳中风—包含—营卫不和	某证候由若干病机构成
	治法—包含—方剂	和法—包含—小柴胡汤	治法是一类方剂的归属分类
组成	药物—组成—方剂	桂枝等中药—组成—桂枝汤	方剂由若干中药组成
导致	病因—导致—病名	寒邪—导致—伤寒	寒邪是导致伤寒的外在诱因
	病因—导致—证候	寒邪—导致—太阳中风	病因引发某一证候的出现

(2) 实体与关系抽取

基于已构建的本体体系,采用人工标注与模型抽取相结合的混合策略进行经方实体与关系抽取。在人工标注与模型训练阶段,选取《伤寒论》原文中200条条文进行人工实体与关系标注;结合领域词表与专家经验明确粒度划分,形成训练语料;使用200条标注数据训练命名实体识别模型BERT-BiLSTM-CRF^[33]与关系识别模型BiLSTM-ResNet^[34]。在自动抽取与审核修正阶段,使用训练好的知识抽取模型对剩余198条条文进行自动抽取;以全国科学技术名词审定委员会公布的《中医药学名词》标准进行语义消歧^[35];再由中医药知识专家逐条复核与修正抽取结果,确保经方知识图谱质量。构建完成的经方知识图谱共计包含3 536条结构化三元组,覆盖中

药、方剂、证候、症状等核心中医实体,三元组实体类型、关系类型及相应数量如表5和表6所示。

表5 三元组实体类型及相应数量

Table 5 Entity Types and Their Corresponding Counts in the Knowledge Graph Triples

实体	数量
症状	1 297
药物	567
体征	369
病机	318
方剂	285
证候	221
病名	147
病因	140
治法	139
总数	3 483

表 6 三元组关系类型及相应数量

Table 6 Relation Types and Their Corresponding Counts in the Knowledge Graph Triples

关系	数量
临床表现	1 278
治疗	1 157
包含	676
组成	285
导致	140
总数	3 536

(3) 描述性文本准备与语义对应

为支持后续实体表示学习模块,将已构建的经方知识图谱中的每个实体与古籍中对应的语义描述条文进行关联。《伤寒论》中的原文条文作为经方知识图谱构建数据的直接文本语料,《金匱要略》等相关古籍中出现的同名实体条文则用于扩充实体的语义上下文。通过人工方式完成条文与实体的一一对应,并统一转换为实体描述语料集合,用于后续基于 PLMs 的表示学习。

4.3 实验设计

(1) 任务定义与数据划分

本研究围绕知识图谱补全任务展开,即在给定两项元素时预测第三项。例如,头实体预测或尾实体预测就是在 $(, r, t)$ 或 $(h, r,)$ 的情形下推断缺失实体。以经方知识图谱为基础,将全部三元组按关系类型进行分层随机划分,确保训练集、验证集与测试集在关系分布上的一致性,比例分别设定为 80%、10%、10%。在不同随机种子下重复实验 5 次,记录各指标的均值与标准差。

(2) 评价指标

采用知识图谱推理领域的主流指标评估模型性能,包括平均倒数排名 (Mean Reciprocal Rank, MRR) 和排序 n 以内的占比 (Hits@ n)。其中, MRR 值越大表明预测排名越靠前,结果也就越好; Hits@ n 表示正确实体排名在前 n 名的比例,该值越大说明模型预测越准确,在测试中 n 值分别取 1、3、10。

(3) 基线模型与对照设置

选取 TransE^[12]、DistMult^[13]、Simple^[36] 与 ComplEx^[14] 作为基线模型,在统一的训练参数与早停策略 (Early Stopping) 下进行比较。在此基础上,在每个

基线模型上分别接入两种文本增强变体:一是 BERT 参数冻结的 BERT-Static,仅训练上层融合与图谱参数;二是在训练过程中对 BERT 进行微调的 BERT-Dynamic,用于检验古籍描述带来的增益及微调的性能提升。为进行方法的横向对比,引入同样利用实体描述的 DKRL^[15] 作为参照,并将中文 BERT 的静态句向量作为 DKRL 的文本输入,即选择 300 维输入、128 维输出的静态 BERT 嵌入作为 DKRL 模型的输入,最大程度控制分词和预训练语料差异造成的影响。实验中, BERT 模型采用针对中文文本的版本 BERT-Base-Chinese。因此,对规范化后的古籍句段直接编码,尽量保持原貌,仅做去重、去无意义标点与异体字统一等最小清洗,排除分词与预训练语料差异带来的影响。所有实体描述均与标准术语体系对齐,在构建阶段完成同义归并,确保每个实体至少拥有一段有效描述文本。

(4) 超参数与消融实验设计

模型训练时,将一次输入 BERT 模型的文本最大长度设定为 32,学习率 (Learning Rate) 分别选择 1×10^{-5} 、 2×10^{-5} 、 5×10^{-5} , L2 正则化系数分别选择 0、 10^{-2} 、 10^{-3} ,迭代次数与训练批次根据训练的实际测试情况进行逐步调整,采用 Adam 作为优化算法。验证集 MRR 在连续 5 个评估周期未提升则停止训练。验证集中表现最好的模型作为最终模型用于中医药知识图谱推理测试。

在消融实验阶段,分析文本长度对模型性能与训练成本的影响。文本最大长度默认设置为 32。将 BERT 输入文本长度从 16 开始,每次增加 16,最大设置为 224,同时评估推理性能与训练时长之间的折中关系。为分析古籍描述微调对知识图谱推理性能的影响,仅改变是否对 BERT 进行微调这一自变量进行消融实验,包括 BERT-Static 与 BERT-Dynamic 两组实验。其中, BERT-Static 组冻结所有 Transformer 层参数,不对 BERT 模型进行微调,具有训练速度快、显存占用低等特点,但难以实现中医药领域数据的自适应学习; BERT-Dynamic 组在训练过程中解冻并更新 BERT 参数,联合优化中医古籍文本语义与知识图谱推理任务。该策略会增加训练时间与显存消耗,但通常能够取得更优的性能表现。

4.4 实验结果分析

在中医经方知识图谱基础上进行中医知识图谱推理实验,知识图谱推理旨在通过最小化得分函数预测给定的知识图谱三元组 (h, r, t) 丢失的 h 或者 t , 对一系列候选实体进行排名,而非从知识图谱中给出一个最佳答案,即在全体候选实体集上计算得分并排序,最终统计排名。在实验中,对于给定的三元组,使用知识图谱实体集中的全部实体随机替换三元组中的头实体或者尾实体,然后按照得分函数递减进行排序。采用 MRR 和 $\text{Hit}@n (n \in \{1, 3, 10\})$ 两项指标对知识图谱推理性能进行评价。对 TransE、DistMult、Simple、ComplEx 等 4 个基线模型在中医

经方知识图谱推理任务上进行复现实验。在此基础上结合 BERT 模型,融合中医古籍中实体的描述信息进行比较实验。

中医经方知识图谱推理实验结果如表 7 所示。在 4 个基线模型中,ComplEx 的 MRR 最优(0.089),融合中医古籍描述后的中医药知识图谱推理模型性能较 TransE、DistMult、Simple、ComplEx 等基线模型均显著提升。对于 BERT-Static 组(BERTs-),相对于各自的基线模型,优化模型在 MRR、Hits@1、Hits@3 和 Hits@10 等 4 个指标上,推理性能的绝对值分别平均提升了 0.087, 0.043, 0.079 和 0.178。对于 BERT-Static-DKRL 组(BERTs-DKRL-)则提升了 0.144, 0.066, 0.147 和 0.269。

表 7 中医经方知识图谱推理实验结果
Table 7 Reasoning Results on the Jingfang Knowledge Graph

模型	MRR	相对提升(%)	Hits@1	相对提升(%)	Hits@3	相对提升(%)	Hits@10	相对提升(%)
TransE	0.062	—	0.020	—	0.059	—	0.181	—
BERTs-TransE	0.184	195.2	0.075	274.6	0.164	180.0	0.474	162.2
BERTs-DKRL-TransE	0.237	280.1	0.097	384.6	0.269	360.5	0.517	186.1
BERTd-TransE	0.257	311.5	0.115	473.1	0.282	381.5	0.544	200.9
DistMult	0.079	—	0.036	—	0.082	—	0.150	—
BERTs-DistMult	0.145	84.4	0.067	86.1	0.132	61.7	0.260	73.1
BERTs-DKRL-DistMult	0.204	159.5	0.082	126.4	0.190	132.3	0.368	145.0
BERTd-DistMult	0.250	217.8	0.116	223.3	0.273	233.5	0.513	241.4
Simple	0.081	—	0.042	—	0.077	—	0.148	—
BERTs-Simple	0.163	100.9	0.082	95.7	0.145	89.2	0.287	93.5
BERTs-DKRL-Simple	0.217	168.4	0.115	172.0	0.206	168.5	0.367	148.0
BERTd-Simple	0.270	234.0	0.128	203.8	0.299	290.2	0.546	268.5
ComplEx	0.089	—	0.047	—	0.093	—	0.161	—
BERTs-ComplEx	0.166	86.7	0.091	93.8	0.185	99.7	0.331	105.7
BERTs-DKRL-ComplEx	0.228	156.7	0.116	147.8	0.235	153.7	0.462	186.6
BERTd-ComplEx	0.269	202.8	0.131	179.7	0.294	218.2	0.547	239.8

(注:s表示静态实体嵌入,BERT模型不进行微调;d表示动态实体嵌入,BERT模型进行微调。)

当 BERT 经过微调后,BERT-Dynamic 组(BERTd-)的 4 项指标相对于各自基线模型,推理性能在绝对值上分别平均提升了 0.184, 0.086, 0.209 和 0.378。从绝对值看,BERTd-Simple 的 MRR 值(0.270)最高,而 BERTd-ComplEx 在 Hits@10(0.547)上略占优势;相对于最佳基线模型(ComplEx;MRR=0.089;TransE:Hits@10=0.181),两者分别在 MRR 与 Hits@10 上得到显著提升。

与未经微调的模型相比,微调 BERT 后的模型推理性能提升是稳定且显著的。在上述 4 项指标下,4 类模型的平均性能提升分别为 60.1%、56.6%、86.0% 和 66.9%。这表明对古籍文本表征进行任务化自适应,可有效提高高位命中率与整体排序质量,尤其对需要更强语义判别的 Hits@3 与 Hits@10 指标提升更为明显。同时,BERTs-DKRL 模型的性能通常介于 BERTs-与 BERTd-之间,表明卷积特征提

取与静态语义表示的建模方式能够在不增加微调成本的情况下进一步利用实体描述信息,但其整体性能仍不及端到端微调所带来的性能提升。

综合实验结果可以看出,在 4 类基线模型中引入中医古籍描述信息后,知识图谱推理性能均得到显著提升。其中,TransE 类模型的性能提升幅度最大,这说明原本表示学习能力相对有限的翻译模型在获得高质量语义描述后,其表示能力得到明显增强;同时,Complex 和 Simple 等能够较好建模非对称复杂关系的表示学习模型,在文本增强后其推

理性能也得到进一步提升,其中 BERTd-Complex 在 Hits@10 指标上达到 0.547。总体而言,中医古籍所蕴含的高密度领域语义信息能够与知识图谱结构信息形成有效互补,不仅改善了长尾实体与稀疏关系的可区分性,也提升了整体知识图谱推理的稳健性与鲁棒性。

为评估文本长度对知识图谱推理能力与训练代价的影响,将 BERT 输入的最大文本长度从 16 个中文字符逐步递增到 224 个中文字符,并在 4 个融合模型上进行消融实验,实验结果如图 2 所示。




图 2 中医古籍文本长度消融实验结果

Fig.2 Ablation Study Results for Text Length of Classical TCM

随着实体描述文本长度的增加,知识图谱推理性能整体呈上升趋势,但当文本长度达到 96 个中文字符后,MRR 的提升幅度明显减缓,性能增长趋于稳定。同时,模型训练时间随输入长度增加呈近似线性增长。综合考虑推理性能与训练效率,当文本长度为 96 个中文字符时能够取得较优的性能与效率平衡。该长度既能覆盖中医古籍中关于方证、药性等关键信息的核心语句,又能够有效控制模型训练的计算开销。因此,在实际训练知识图谱推理模

型时,合理设置文本输入长度,并在推理性能与训练成本之间取得平衡,是一种具有实践可行性的技术策略。

综上所述,融合古籍描述信息的中医药知识图谱推理相比于基线模型,均取得了显著的性能提升。其中,相比于静态模型,经过微调后的 BERT 模型能够实现文本语义信息与知识图谱结构信息之间的深度对齐,从而获得更优的推理性能。在实际应用中,对于精度要求较高的应用场景,建议采用 BERTd-框

架以获得更优的推理效果;而在资源受限或成本敏感的场景下,可采用BERTs-DKRL框架作为一种计算开销较低的替代方案。

5 结 语

本文针对中医药知识图谱中结构稀疏、语义隐含且专业性强的问题,研究融合中医古籍文本增强知识推理能力的方法。以《伤寒论》为代表性研究对象,通过人工标注与自动抽取相结合的方式构建中医经方知识图谱,并将中医古籍条文作为实体描述信息,引入预训练语言模型进行语义表示,与知识图谱结构嵌入联合建模,从而形成面向中医药领域的知识图谱推理方法。研究表明,中医古籍所蕴含的高密度领域语义能有效补充知识图谱结构信息,提高中医药知识推理能力,并为中医智能问答、经方推荐和知识检索等应用提供支持。本文实验数据来源于中医经典论著,知识图谱规模仍然有限,对关系路径、规则推理及领域预训练模型等增强机制尚未开展系统研究,未来可在更大规模中医药数据与多源知识融合框架下进一步探索。

参考文献:

- [1] 邓宇,周卫强,张振铭,等. 基于名老中医医案的知识图谱构建[J]. 湖南中医杂志, 2019, 35(7): 186-187. (Deng Yu, Zhou Weiqiang, Zhang Zhenming, et al. Construction of Knowledge Map Based on Famous and Old Chinese Medical Records[J]. Hunan Journal of Traditional Chinese Medicine, 2019, 35(7): 186-187.)
- [2] 高晓苑,高文佳,王欣宇,等. 基于医案文本的名老中医诊疗知识图谱构建方法及应用[J]. 世界科学技术-中医药现代化, 2023, 25(9): 2967-2974. (Gao Xiaoyuan, Gao Wenjia, Wang Xinyu, et al. Research on the Construction Method and Application of Diagnosis and Treatment Knowledge Graph of Famous TCM Physicians Based on Medical Records[J]. Modernization of Traditional Chinese Medicine and Materia Medica-World Science and Technology, 2023, 25(9): 2967-2974.)
- [3] 高甦,金佩,张德政. 基于深度学习的中医典籍命名实体识别研究[J]. 情报工程, 2019, 5(1): 113-123. (Gao Su, Jin Pei, Zhang Dezheng. Research on Named Entity Recognition of TCM Classics Based on Deep Learning[J]. Technology Intelligence Engineering, 2019, 5(1): 113-123.)
- [4] Xu W X, Wang L, Zhang M C, et al. A Joint Entity Relation Extraction Method for Document Level Traditional Chinese Medicine Texts[J]. Artificial Intelligence in Medicine, 2024, 154. DOI: 10.1016/j.artmed.2024.102915.
- [5] 杨晓欢,单娅辉,解丹,等. 面向文摘的中药方剂与疾病关系抽取[J]. 世界科学技术-中医药现代化, 2017, 19(7): 1167-1172. (Yang Xiaohuan, Shan Yahui, Xie Dan, et al. Relation Extraction of Traditional Chinese Medicine Prescription and Disease Based on Literature Abstracts Data[J]. Modernization of Traditional Chinese Medicine and Materia Medica-World Science and Technology, 2017, 19(7): 1167-1172.)
- [6] 贾李蓉,高博,刘静,等. 基于中医药学语言系统的知识问答系统设计[J]. 医学信息学杂志, 2021, 42(6): 52-55. (Jia Lirong, Gao Bo, Liu Jing, et al. Design of the Knowledge Question Answering System Based on the Traditional Chinese Medicine Language System[J]. Journal of Medical Informatics, 2021, 42(6): 52-55.)
- [7] Miao F, Wang X T, Zhang P, et al. Question-Answering System Based on the Knowledge Graph of Traditional Chinese Medicine [C]//Proceedings of the 11th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). IEEE, 2019: 264-267.
- [8] 郑懿鸣,翟洁,胡晓龙,等. 基于中医药知识图谱的智能问答与用药推荐系统[J]. 电子技术与软件工程, 2019(20): 134-135. (Zheng Yiming, Zhai Jie, Hu Xiaolong, et al. Intelligent Question Answering and Drug Recommendation System Based on TCM Knowledge Map[J]. Electronic Technology & Software Engineering, 2019(20): 134-135.)
- [9] Zhang W B, Dang H B, Bao Z S, et al. LAMGCN: Traditional Chinese Medicine Herb Recommendation via LSTMS with Attention Mechanisms and Graph Convolutional Networks[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2025, 24(3): Article No.27.
- [10] Alshahrani M, Thafar M A, Essack M. Application and Evaluation of Knowledge Graph Embeddings in Biomedical Data [J]. PeerJ Computer Science, 2021, 7. DOI: 10.7717/peerj-cs.341.
- [11] Shi F B, Li D, Wang X G, et al. TGformer: A Graph Transformer Framework for Knowledge Graph Embedding[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(1): 526-541.
- [12] Bordes A, Usunier N, García-Durán A, et al. Translating Embeddings for Modeling Multi-Relational Data[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. 2013: 2787-2795.
- [13] Yang B S, Yih W T, He X D, et al. Embedding Entities and Relations for Learning and Inference in Knowledge Bases[C]//Proceedings of the 2015 International Conference on Learning Representations. 2015: 1-12.
- [14] Trouillon T, Welbl J, Riedel S, et al. Complex Embeddings for Simple Link Prediction[OL]. arXiv Preprint, arXiv: 1606.06357.

- [15] Xie R B, Liu Z Y, Jia J, et al. Representation Learning of Knowledge Graphs with Entity Descriptions[C]//Proceedings of the 13th AAAI Conference on Artificial Intelligence. ACM, 2016: 2659-2665.
- [16] 韩青, 周晓英. 基于文献共被引特征的文献相似度计算优化研究[J]. 情报学报, 2018, 37(9): 905-911. (Han Qing, Zhou Xiaoying. Research on Optimization of Scientific Literature Similarity Calculation Based on the Co-Citation Feature[J]. Journal of the China Society for Scientific and Technical Information, 2018, 37(9): 905-911.)
- [17] 罗基, 张宇洁, 张林帅, 等. 中医古籍事理图谱构建——以《伤寒论》为例[J]. 世界科学技术-中医药现代化, 2024, 26(11): 2878-2887. (Luo Ji, Zhang Yujie, Zhang Linshuai, et al. Construction of Event Evolution Graph of Ancient Chinese Medicine Books-Taking Treatise on Febrile Diseases as an Example[J]. Modernization of Traditional Chinese Medicine and Materia Medica-World Science and Technology, 2024, 26(11): 2878-2887.)
- [18] Zhang W, Liu T T, Li Z M, et al. Multimodal Knowledge Graph Embedding with Self-Attention Graph Neural Network[J]. IEEE Transactions on Computational Social Systems, 2025. DOI: 10.1109/TCSS.2025.3556073.
- [19] Wang Z, Zhang J W, Feng J L, et al. Knowledge Graph Embedding by Translating on Hyperplanes[C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence. 2014: 1112-1119.
- [20] Moon C, Jones P, Samatova N. Learning Entity Type Embeddings for Knowledge Graph Completion[C]//Proceedings of the 2017 ACM Conference on Information and Knowledge Management. 2017: 2215-2218.
- [21] Ji G, He S, Xu L, et al. Knowledge Graph Embedding via Dynamic Mapping Matrix[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. 2015: 687-696.
- [22] Sun Z Q, Deng Z H, Nie J Y, et al. RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space[OL]. arXiv Preprint, arXiv: 1902.10197.
- [23] Zhang S, Tay Y, Yao L N, et al. Quaternion Knowledge Graph Embeddings[C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. 2019: 2735-2745.
- [24] Reimers N, Gurevych I. Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks[OL]. arXiv Preprint, arXiv: 1908.10084.
- [25] Yao L, Mao C S, Luo Y. KG-BERT: BERT for Knowledge Graph Completion[OL]. arXiv Preprint, arXiv: 1909.03193.
- [26] Wang X Z, Gao T Y, Zhu Z C, et al. KEPLER: A Unified Model for Knowledge Embedding and Pre-Trained Language Representation[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 176-194.
- [27] Sun T X, Shao Y F, Qiu X P, et al. CoLAKE: Contextualized Language and Knowledge Embedding[OL]. arXiv Preprint, arXiv: 2010.00309.
- [28] Liu W J, Zhou P, Zhao Z, et al. K-BERT: Enabling Language Representation with Knowledge Graph[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(3): 2901-2908.
- [29] Zhang Z, Han X, Liu Z, et al. ERNIE: Enhanced Language Representation with Informative Entities[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 1441-1451.
- [30] Ethayarajh K. How Contextual are Contextualized Word Representations? Comparing the Geometry of BERT, ELMo, and GPT-2 Embeddings[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 55-65.
- [31] Devlin J, Chang M W, Lee K, et al. BERT: Pre-Training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2019: 4171-4186.
- [32] Noy N, McGuinness D L. Ontology Development 101: A Guide to Creating Your First Ontology[R]. Stanford University, 2001.
- [33] Liu Y F, Wei S Q, Huang H J, et al. Naming Entity Recognition of Citrus Pests and Diseases Based on the BERT-BiLSTM-CRF Model[J]. Expert Systems with Applications, 2023, 234: 121103.
- [34] Shao S L, Han G J, Wang T, et al. EEG-Based Mental Workload Classification Method Based on Hybrid Deep Learning Model Under IoT[J]. IEEE Journal of Biomedical and Health Informatics, 2024, 28(5): 2536-2546.
- [35] 中医药学名词审定委员会. 中医药学名词:2004 [M]. 北京: 科学出版社, 2005. (China National Committee for Terminology in Traditional Chinese Medicine. Terminology of Traditional Chinese Medicine: 2004 [M]. Beijing: Science Press, 2005.)
- [36] Kazemi S M, Poole D L. Simple Embedding for Link Prediction in Knowledge Graphs[C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems. 2018: 4289-4300.

作者贡献声明:

韩青: 研究方案设计与技术路线制定, 数据标注与数据处理, 构建知识图谱与推理模型, 开展实验与结果分析, 撰写论文初稿;
周晓英: 研究问题界定与整体研究框架设计, 参与实验方案制定与结果分析, 论文结构优化与内容完善, 完成论文修改与定稿。

利益冲突声明：

所有作者声明不存在利益冲突关系。

[1] 周晓英. 中医经方文本数据集. E-mail:xyz-ruc@qq.com.
[2] 韩青. 中医经方知识图谱. E-mail:hanqing@zcmu.edu.cn.

支撑数据：

支撑数据由作者自存储。

收稿日期:2024-04-27
收修改稿日期:2025-10-07

Knowledge Graph Reasoning for Traditional Chinese Medicine Enhanced by Classical Texts

Han Qing¹ Zhou Xiaoying²

¹(School of Medical Technology and Information Engineering, Zhejiang Chinese Medical University, Hangzhou 310053, China)

²(School of Information Resource Management, Renmin University of China, Beijing 100872, China)

Abstract: [Objective] This study introduces classical traditional Chinese medicine (TCM) texts as entity descriptions into representation learning models to improve knowledge graph reasoning performance, addressing the problems of structural sparsity and insufficient utilization of semantic information in TCM knowledge graphs. [Methods] A classical formula knowledge graph was constructed using 398 clauses from *Shanghan Lun* as the primary corpus, combining manual annotation and automatic extraction in a hybrid process. Relevant passages from *Shanghan Lun* and *Jinkui Yaolue*, associated with the graph's entities, were used as textual descriptions and were encoded using a pre-trained language model. Knowledge graph reasoning experiments were conducted by integrating static BERT representations (BERT-Static) and fine-tuned BERT representations (BERT-Dynamic) with several baseline models, including TransE, DistMult, ComplEx, and Simple. [Results] On the Jingfang knowledge graph, the reasoning models enhanced with classical text information consistently outperformed their corresponding baseline models in MRR, Hits@1, Hits@3, and Hits@10. In absolute terms, MRR increased from 0.062~0.089 to 0.257~0.270, and Hits@10 increased from 0.148~0.181 to 0.513~0.547. Ablation experiments on input length further indicated that model performance improved as the BERT input length increasing from 16 to 96 Chinese characters, but improvements became marginal beyond this point while training time increased approximately linearly. [Limitations] The experimental data mainly derive from passages in *Shanghan Lun* and *Jinkui Yaolue*, and the scale of the knowledge graph remains relatively limited. Moreover, the proposed method only considers the joint representation of entity descriptions and structural triples, while additional structural enhancement mechanisms such as relation paths and rule-based reasoning are not yet incorporated. [Conclusions] Incorporating classical TCM texts as entity descriptions and integrating them with pre-trained language models can effectively enhance knowledge representation and significantly improve reasoning performance in TCM knowledge graphs.

Keywords: Traditional Chinese Medicine Classical Texts Knowledge Graph Reasoning
Pre-Trained Language Models Jingfang Knowledge Graph Representation Learning